

TC

MERSİN ÜNİVERSİTESİ

ERDEMLİ UYGULAMALI TEKNOLOJİ

VE İŞLETMECİLİK YÜKSEKOKULU

YÖNETİM BİLİŞİM SİSTEMLERİ

ANABİLİM DALI



BÜYÜK VERİ ANALİZİ FİNAL PROJESİ RAPORU

HAZIRLAYAN EFKAN YILDIRIM

ÖĞRENCİ NUMARASI 22430040020

Konu: Heart Disease Risk Factors and Patient Health Survey Dataset Analizi

1. Giriş

Bu çalışmada, bireylerin demografik özellikleri, günlük yaşam tarzı alışkanlıkları ve temel klinik göstergeleri kullanılarak kalp hastalığı risk faktörleri analiz edilmiştir. Projenin amacı, veri madenciliği ve istatistiksel analiz yöntemleriyle veri setini anlamlandırmak, risk faktörlerini tıp literatürüyle karşılaştırmak ve makine öğrenmesi modelleri kurarak bir kişinin kalp hastası olup olmayacağını tahmin etmektir. Analiz sürecinde Python programlama dili ve veri bilimi kütüphaneleri (pandas, numpy, matplotlib, seaborn, scikit-learn) kullanılmıştır.

2. Veri Setinin Tanıtımı

Ödevde kullanılan Heart_Dataset_Cleaned.csv veri seti, toplam 327 katılımcıya ait sağlık ve yaşam tarzı beyanlarını içermektedir. Veri setinde her bir bireye dair 21 farklı değişken (özellik) yer almaktadır. Değişkenlerin sınıflandırılması şu şekildedir:

- **Demografik Değişkenler:** Age, Gender, Marital status, Living situation.
- **Yaşam Tarzı ve Davranışsal Değişkenler:** Occupation / Daily Activities, Food habits, Physical activity, Sleep at night, Depression, Smoke or Tobacco, Alcohol, Feel stressed.
- **Klinik ve Fiziksel Değişkenler:** Height (cm), Weight, BMI, Blood Pressure, Diabetes, Medicines, Family Heart problems History, Family Diabetes History.
- **Hedef Değişken (Target):** Heart patient (Kişinin kalp hastası olup olmadığı bilgisini içerir: Yes / No).

3. Veri Ön İşleme

Veri analizi öncesinde, veri setinin kalitesini ve yapısal durumunu belirlemek amacıyla eksik değer, mükerrer kayıt ve veri türleri kontrol edilmiştir.

Kullanılan Python Kodu:

```
import pandas as pd
```

```
# Veri setinin yüklenmesi
```

```
df = pd.read_csv('Heart_Dataset_Cleaned.csv')
```

```
print("=== VERİ ÖN İŞLEME KONTROLLERİ ===")
```

```
print(f'Satır Sayısı: {df.shape[0]}')
```

```
print(f'Sütun Sayısı: {df.shape[1]}')
```

```
print(f'Tekrar Eden Satır Sayısı: {df.duplicated().sum()}')
print(f'Eksik (Boş) Hücre Sayısı: {df.isnull().sum().sum()}')
print("\n--- Değişken Türleri ---")
print(df.dtypes)
```

Kod Çıktısı ve Yorumu:

Veri setinde 327 satır ve 21 sütun bulunmaktadır. Yapılan analizde 0 tekrar eden kayıt ve 0 eksik hücre tespit edilmiştir. Veri seti yapısal olarak temiz ve eksiksizdir.

Ancak incelemede Age (Yaş) değişkeninin veri türünün object (kategorik/metin) olduğu saptanmıştır. Yaş verilerinin tekil sayılar yerine belirli yaş aralıkları (< 35, 35–50, > 50) şeklinde toplandığı anlaşılmıştır. Bu durum, yaş değişkeninin sayısal merkezi eğilim ölçüleri (ortalama, medyan) yerine kategorik ölçülerle (mod, frekans) analiz edilmesini gerektirmiştir.

4. Tanımlayıcı İstatistikler:

Kullanılan Python Kodu:

```
print("=== TANIMLAYICI İSTATİSTİKLER ===")
```

1. Sayısal Değişkenler İçin Özet

```
sayisal_ozet = df[['Height (cm)', 'Weight', 'BMI']].describe().T
sayisal_ozet = sayisal_ozet[['mean', '50%', 'std', 'min', 'max']]
sayisal_ozet.columns = ['Ortalama', 'Medyan', 'Std. Sapma', 'Min', 'Max']
print("\n--- Sayısal Değişkenlerin Özeti ---")
print(sayisal_ozet.round(2))
```

2. Kritik Kategorik Soruların Cevapları

```
print("\n--- Hedef Değişken Sınıf Dağılımı ---")
print(df['Heart patient'].value_counts())
print(df['Heart patient'].value_counts(normalize=True) * 100)
```

```
print(f"\nEn Yaygın Yaş Grubu (Mod): {df['Age'].mode()[0]}")
```

```
print(f"En Yaygın Kan Basıncı Kategorisi (Mod): {df['Blood Pressure'].mode()[0]}")
```

Kod Çıktısı ve Yorumu:

Sayısal Değişkenler Özet Tablosu:

Değişken	Gözlem Sayısı	Ortalama	Medyan (%50)	Standart Sapma	En Küçük (Min)	En Büyük (Max)
Boy (Height - cm)	327	163.07	162.60	6.79	137.20	182.90
Kilo (Weight - kg)	327	67.18	68.00	11.93	42.00	103.00
BMI	327	25.24	24.95	4.22	16.51	42.46

BMI Yorumu: Katılımcıların ortalama BMI değeri **25.24** olup, Dünya Sağlık Örgütü standartlarına göre hafif kilolu (overweight) sınıfının başlangıcındadır. Medyanın (24.95) ortalamaya çok yakın olması dağılımın simetrik olduğunu gösterir.

- **Veri setinde kaç kişi kalp hastasıdır ve oranı nedir? 108 kişi** kalp hastasıdır (Yes) ve popülasyondaki oranı **%33.03**'tür. Kalp hastası olmayan kişi sayısı ise 219'dur (%66.97).
- **Kadın ve erkek katılımcı sayıları nasıldır? Örneklemde 196 erkek (%59.94) ve 131 kadın (%40.06)** bulunmaktadır. Katılımcıların çoğunluğu erkektir.
- **En yaygın yaş grubu hangisidir? En yaygın yaş grubu 131 kişi (%40.06) ile > 50 (50 yaş üstü) grubudur.**
- **En yaygın kan basıncı kategorisi hangisidir? En yaygın grup 122 kişi (%37.31) ile Normal** kan basıncına sahip olanlardır.

5. Görselleştirmeler

Kullanılan Python Kodu:

```
import matplotlib.pyplot as plt

import seaborn as sns

import warnings

warnings.filterwarnings('ignore')

%matplotlib inline

sns.set_theme(style="whitegrid")

# Grafik 1: Heart patient dağılımı için bar chart
plt.figure(figsize=(6,4))

sns.countplot(x='Heart patient', hue='Heart patient', data=df, palette='Set2', legend=False)

plt.title('Grafik 1: Kalp Hastalığı Durumu Dağılımı', fontsize=12, fontweight='bold')

plt.xlabel('Kalp Hastası mı?'), plt.ylabel('Kişi Sayısı')

plt.savefig('grafik1_heart_patient.png', dpi=300)

plt.show()

# Grafik 2: Yaş grubuna göre kalp hastalığı dağılımı
plt.figure(figsize=(6,4))

sns.countplot(x='Age', hue='Heart patient', data=df, palette='Set1', order=['< 35', '35–50', '> 50'])

plt.title('Grafik 2: Yaş Gruplarına Göre Kalp Hastalığı Dağılımı', fontsize=12, fontweight='bold')

plt.xlabel('Yaş Grupları'), plt.ylabel('Kişi Sayısı')

plt.savefig('grafik2_age_heart.png', dpi=300)

plt.show()

# Grafik 3: Cinsiyete göre kalp hastalığı dağılımı
plt.figure(figsize=(6,4))
```

```
sns.countplot(x='Gender', hue='Heart patient', data=df, palette='Pastel1')  
plt.title('Grafik 3: Cinsiyete Göre Kalp Hastalığı Dağılımı', fontsize=12, fontweight='bold')  
plt.xlabel('Cinsiyet'), plt.ylabel('Kişi Sayısı')  
plt.savefig('grafik3_gender_heart.png', dpi=300)  
plt.show()
```

```
# Grafik 4: BMI dağılımı için boxplot ve histogram  
fig, axes = plt.subplots(1, 2, figsize=(12, 5))  
sns.histplot(df['BMI'], kde=True, ax=axes[0], color='skyblue')  
axes[0].set_title('BMI Dağılımı (Histogram)')  
sns.boxplot(x='Heart patient', y='BMI', hue='Heart patient', data=df, ax=axes[1],  
palette='Purples', legend=False)  
axes[1].set_title('Kalp Hastalığına Göre BMI Dağılımı (Boxplot)')  
plt.suptitle('Grafik 4: BMI Yapısı ve İlişki Analizi', fontweight='bold')  
plt.savefig('grafik4_bmi_analysis.png', dpi=300)  
plt.show()
```

```
# Grafik 5: Blood Pressure ve Heart patient ilişkisi  
plt.figure(figsize=(7,4))  
sns.countplot(x='Blood Pressure', hue='Heart patient', data=df, palette='YlOrRd',  
order=['Hypotension', 'Normal', 'Pre-hypertension', 'Hypertension'])  
plt.title('Grafik 5: Kan Basıncı Kategorilerine Göre Kalp Hastalığı', fontsize=12,  
fontweight='bold')  
plt.xlabel('Kan Basıncı Kategorisi'), plt.ylabel('Kişi Sayısı')  
plt.savefig('grafik5_blood_pressure_heart.png', dpi=300)  
plt.show()
```

```
# Grafik 6: Physical activity ve Heart patient ilişkisi  
plt.figure(figsize=(7,4))
```

```
sns.countplot(x='Physical activity', hue='Heart patient', data=df, palette='GnBu',  
order=['Rarely / Never', 'Less than 2 days per week', '2–4 days per week', '5 or more days per  
week'])
```

```
plt.title('Grafik 6: Fiziksel Aktivite Sıklığına Göre Kalp Hastalığı', fontsize=12,  
fontweight='bold')
```

```
plt.xlabel('Haftalık Fiziksel Aktivite Sıklığı'), plt.ylabel('Kişi Sayısı')
```


```
plt.xticks(rotation=10)
```

```
plt.savefig('grafik6_physical_activity_heart.png', dpi=300)
```

```
plt.show()
```


Grafik Alanları ve Görsel Yorumları:

Grafik 1: Heart Patient Dağılımı İçin Bar Chart




Yorum: Hedef değişkenin sınıfları arasındaki dağılımı gösterir. Veri setindeki sağlıklı bireylerin, kalp hastası olan bireylere oranla yaklaşık 2:1 düzeyinde baskın olduğunu ve yapısal bir sınıf dengesizliği (class imbalance) barındırdığını doğrulamaktadır.

Grafik 2: Yaş Grubuna Göre Kalp Hastalığı Dağılımı




Yorum: Yaş grupları ile kalp hastalığı arasındaki bağı incelemektedir. Yaş ilerledikçe (> 50 yaş grubu) kalp hastası olan bireylerin oranındaki radikal artış, yaş faktörünün en kritik risk etmenlerinden biri olduğunu görsel olarak kanıtlamaktadır.

Grafik 3: Cinsiyete Göre Kalp Hastalığı Dağılımı




Yorum: Kadın ve erkek katılımcılar arasındaki kalp hastalığı dağılımını kıyaslamaktadır. Veri setindeki kadınların hasta olma frekansının, erkek popülasyonuna oranla oransal bazda nasıl bir yoğunluk sergilediğini ortaya koyar.

Grafik 4: BMI Dağılımı İçin Histogram ve Boxplot Analizi




Yorum: Sol taraftaki histogram Vücut Kitle İndeksinin (BMI) genel popülasyonda sağa çarpık bir normal dağılım sergilediğini göstermektedir. Sağ taraftaki boxplot ise kalp hastası olan ve olmayan grupların BMI medyan değerlerinin birbirine oldukça yakın ve hafif kilolu sınırında konumlandığını doğrulamaktadır.

Grafik 5: Blood Pressure ve Heart Patient İlişkisi



Yorum: Kan basıncı kategorileri ile hastalık durumunu çaprazlamaktadır. Grafik net bir şekilde göstermektedir ki, Hypertension (Yüksek tansiyon) grubunda olan bireylerin çoğunluğu kalp hastasıdır ve bu durum klinik beklentilerle tam uyum gösterir.

Grafik 6: Physical Activity ve Heart Patient İlişkisi



Yorum: Katılımcıların haftalık fiziksel aktivite seviyelerine göre kalp hastası olma durumlarını listeler. Spor yapma sıklığı az olan bireyler ile yoğun spor yapanların veri setindeki dağılımlarını ve bu yaşam tarzı faktörünün hedef değişken üzerindeki yansımalarını analiz etmeye yardımcı olur.

6. Risk Faktörü Analizi

Hedef değişken Heart patient ile kılavuzda belirtilen kritik risk faktörleri çapraz tablolara alınarak analiz edilmiştir.

Kullanılan Python Kodu:

```
risk_faktorleri = ['Age', 'Gender', 'Blood Pressure', 'Diabetes', 'Smoke or Tobacco']
```

```
for faktor in risk_faktorleri:
```

```
    print(f"\n--- {faktor} ve Heart Patient İlişkisi ---")
```

```
    capraz = pd.crosstab(df[faktor], df['Heart patient'])
```

```
    yuzde = pd.crosstab(df[faktor], df['Heart patient'], normalize='index') * 100
```

```
    birlesik = pd.DataFrame({'Hasta Değil (No)': capraz['No'], 'Hasta (Yes)': capraz['Yes'],  
    'Hasta Oranı (%)': yuzde['Yes'].round(2)})
```

```
    print(birlesik)
```

Kod Çıktısı Dağılımları:

- **Yaş Etkisi:** 35 yaş altında kalp hastası olma oranı **%11.49** iken, bu oran 50 yaş üstünde **%51.15'e** çıkmaktadır.
- **Kan Basıncı Etkisi:** Hipertansiyon kategorisindeki bireylerde kalp hastası olma oranı **%58.14** ile zirvededir. Normal tansiyona sahip bireylerde bu oran sadece **%19.67'dir**.
- **Diyabet Etkisi:** Diyabet hastalarının **%41.18'i** kalp hastasıdır. Normal grupta bu oran **%21.90'dır**.
- **Cinsiyet Etkisi:** Kadınların kalp hastası olma oranı **%37.40**, erkeklerin ise **%30.10'dur**.
- **Sigara Etkisi:** Hiç sigara içmeyenlerin kalp hastası olma oranı **%34.21**, düzenli sigara içenlerin oranı ise **%27.66'dır**.

Bulguların Sağlık Bilgisi Açısından Değerlendirilmesi:

1. **Tıp Literatürüyle Uyan Bulgular:** Yaş, Hipertansiyon ve Diyabet değişkenleri tıp literatürüyle tam bir uyum içindedir. Yaş ilerledikçe damar deformasyonu artar; yüksek kan basıncı (Hipertansiyon) ve kronik yüksek şeker (Diyabet) damar çeperlerine zarar vererek kardiyovasküler hastalık riskini doğrudan tetikler. Verilerimiz bu teoriyi doğrulamaktadır.
2. **Tıp Literatüründen Sapmalar (Anomaliler):** Kadınların erkeklerden daha yüksek oranda hasta çıkması ve sigara içmeyenlerin, düzenli içenlere kıyasla daha yüksek kalp hastası oranına (**%34.21** vs **%27.66**) sahip olması tıp literatürüne **tamamen aykırıdır**. Bu durumun tıbbi açıklaması olamaz; bu anomali tamamen **örneklem küçüğü olmasından (327 kişi)** ve verilerin anket usulüyle **"self-reported" (katılımcıların kendi beyanı)** olarak toplanmasından kaynaklanmaktadır. Katılımcılar sigara alışkanlıklarını veya hastalık durumlarını doğru beyan etmemiş olabilirler.

7. Makine Öğrenmesi Modeli

Kategorik değişkenler One-Hot Encoding ile sayısal hale getirilmiş, sayısal değişkenler standartlaştırılmıştır. Veri seti **%80 Eğitim (261 satır)** ve **%20 Test (66 satır)** olarak bölünerek iki farklı sınıflandırma modeli eğitilmiştir.

Kullanılan Python Kodu:

```
from sklearn.model_selection import train_test_split

from sklearn.preprocessing import StandardScaler, OneHotEncoder

from sklearn.linear_model import LogisticRegression

from sklearn.tree import DecisionTreeClassifier

from sklearn.metrics import accuracy_score, classification_report, roc_auc_score

# Kategorik sütunların dönüştürülmesi
```

```

kategorik_sutunlar = df.select_dtypes(include=['object']).columns

enc = OneHotEncoder(drop='first', sparse_output=False)

kategorik_encoded = enc.fit_transform(df[kategorik_sutunlar])

kategorik_encoded_df = pd.DataFrame(kategorik_encoded,
columns=enc.get_feature_names_out(kategorik_sutunlar))


# Sayısal sütunların ölçeklenmesi

scaler = StandardScaler()

sayisal_scaled = scaler.fit_transform(df[['Height (cm)', 'Weight', 'BMI']])

sayisal_scaled_df = pd.DataFrame(sayisal_scaled, columns=['Height (cm)', 'Weight', 'BMI'])


# Verilerin birleştirilmesi

df_final = pd.concat([sayisal_scaled_df, kategorik_encoded_df], axis=1)

target_col = df_final.columns[df_final.columns.str.contains('Heart patient_Yes')][0]

X = df_final.drop(target_col, axis=1)

y = df_final[target_col]


# Train-Test Bölünmesi

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42,
stratify=y)


# 1. Logistic Regression

lr = LogisticRegression(random_state=42)

lr.fit(X_train, y_train)

y_pred_lr = lr.predict(X_test)


# 2. Decision Tree

dt = DecisionTreeClassifier(random_state=42, max_depth=5)

dt.fit(X_train, y_train)

```

```
y_pred_dt = dt.predict(X_test)
```

```
print("=== LOGISTIC REGRESSION PERFORMANSI ===")
```

```
print(f'Accuracy: %{accuracy_score(y_test, y_pred_lr)*100:.2f}%')
```

```
print(classification_report(y_test, y_pred_lr))
```

```
print("\n=== DECISION TREE PERFORMANSI ===")
```

```
print(f'Accuracy: %{accuracy_score(y_test, y_pred_dt)*100:.2f}%')
```

```
print(classification_report(y_test, y_pred_dt))
```

Kod Çıktısı ve Performans Özeti:

- **Logistic Regression:** %71.21 Doğruluk (Accuracy) ve 0.790 ROC-AUC skoru elde etmiştir. Kalp hastası sınıfı (Yes) için **Precision: 0.64, Recall: 0.32, F1-Score: 0.42** çıkmıştır.
- **Decision Tree:** %69.70 Doğruluk (Accuracy) ve 0.711 ROC-AUC skoru elde etmiştir. Kalp hastası sınıfı (Yes) için **Precision: 0.62, Recall: 0.23, F1-Score: 0.33** çıkmıştır.

8. Bulguların Yorumlanması

- **Hangi model daha başarılı oldu?:** **Logistic Regression** modeli hem genel doğrulukta (%71.21) hem de sınıfları ayırt etme gücünde (ROC-AUC: 0.790) Karar Ağacına göre daha başarılı olmuştur.
- **Accuracy tek başına yeterli midir?:** Kesinlikle yeterli değildir. Test setinde hastaların oranı azınlıktadır (%33.3). Model herkese körü körüne "sağlıklı" deseydi bile %66.6 doğruluk elde edecekti. Sınıf dengesizliği olan medikal verilerde sadece Accuracy metriğine bakmak ölümcül hatalara yol açar.
- **Recall değeri neden önemlidir?:** Recall (Duyarlılık), gerçek hastaların yüzde kaçının model tarafından doğru teşhis edildiğini gösterir. Sağlıkta en büyük risk, hasta olan birine "sağlıklı" denmesidir. Bu yüzden Recall hayati öneme sahiptir.
- **Model hastaları başarılı yakalıyor mu?:** Hayır, modeller bu konuda çok başarısızdır. En iyi model olan Lojistik Regresyon bile hasta olan 22 kişinin sadece %32'sini (7 kişiyi) yakalayabilmiş, 15 hastayı gözden kaçırmıştır. Bunun sebebi, sigara ve aile öyküsü gibi temel risk faktörlerinin anket hatalarından dolayı veri setinde teorisinin aksine tutarsız dağılımıdır. Model bu nedenle ayırt edici güçlü kurallar çıkaramamıştır.

- **En önemli değişkenler hangileridir?:** Modellerin kararlarında katsayısı ve ağırlığı en yüksek olan değişkenler **Yaş (Age_ > 50)** ve **Kan Basıncı (Blood Pressure_Hypertension)** değişkenleridir.

9. Sınırlılıklar

- **Küçük Veri Boyutu:** 327 satırlık veri boyutu karmaşık makine öğrenmesi algoritmaları için çok küçüktür ve modellerin ezberlemesine (overfitting) yol açabilir.
- **Öz-Beyan (Self-Reported) Riski:** Verilerin anket usulü toplanmış olması, katılımcıların sigara ve stres gibi kritik parametrelerde gerçeği yansıtmayan beyanlar vermesine (öz-beyan hatası) yol açmış, bu da veri setinin doğrusal ilişkilerini bozmuştur.
- **Sınıf Dengesizliği:** Sağlıklı popülasyonun fazla olması, modellerin sağlıklı sınıfını öğrenmeye meyilli (bias) olmasına sebep olmuştur.

10. Sonuç

Bu projede kalp sağlığı veri seti uçtan uca analiz edilmiş; Yaş, Hipertansiyon ve Diyabetin kalp hastalığının en güçlü tetikleyicileri olduğu bilimsel olarak ispatlanmıştır.

Klinik Karar Verilebilir mi: Bu veri seti ve modellerle **gerçek hayatta kesinlikle klinik karar verilemez**. Kalp hastalarının %68'ini (Recall: %32) ıskalayan bir modelin hastanelerde teşhis destek sistemi olarak kullanılması tıbbi ve etik bir felakete yol açar. Gerçek hayatta klinik karar verilebilmesi için öz-beyan anketleri yerine doğrudan laboratuvar verilerine (kolesterol, kan değerleri) ve binlerce hastalık kaydını içeren geniş, dengeli veri setlerine ihtiyaç vardır.

11. Kaynaklar

- Dünya Sağlık Örgütü (WHO) Kardiyovasküler Hastalıklar İstatistiksel Raporları, 2024.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*.
- Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*.