

Büyük Veri Analizi Final Projesi Kısa Sonuç Özeti:

Bu çalışma, 327 katılımcıdan oluşan "Heart Disease Risk Factors" veri seti üzerinde gerçekleştirilen tanımlayıcı istatistik, risk analizleri ve makine öğrenmesi süreçlerini özetlemektedir. Analizlerden elde edilen temel bulgular maddeler halinde aşağıda sıralanmıştır:

- **Veri Kalitesi:** Veri seti üzerinde yapılan ön işlemlerde hiçbir eksik değer (NaN) veya mükerrer (tekrar eden) kayıt tespit edilmemiş, analize eksiksiz bir veri yapısıyla başlanmıştır.
- **Popülasyon Yapısı:** Katılımcıların %59.94'ünü erkekler, %40.06'sını kadınlar oluşturmaktadır. En yaygın yaş grubu 50 yaş üstü bireyler (> 50), en yaygın kan basıncı grubu ise Normal tansiyona sahip olanlardır. Popülasyondaki genel kalp hastası oranı %33.03'tür.
- **Yaş ve Tansiyonun Baskın Etkisi:** Veri setinde tıp literatürüne en paralel ve güçlü sonuçları Yaş ve Kan Basıncı değişkenleri vermiştir. 35 yaş altında kalp hastası olma oranı sadece %11.49 iken, 50 yaş üstünde bu oran %51.15'e fırlamaktadır. Ayrıca, Hipertansiyon hastalarının %58.14'ünün kalp hastası olduğu saptanmıştır.
- **Diyabet Riski:** Diyabet ve prediyabet (gizli şeker) hastalarında kalp hastalığı görülme oranı yaklaşık %41 civarında olup, normal popülasyonun (%21.90) yaklaşık iki katıdır.
- **Veri Setindeki Sapmalar (Anomaliler):** Tıp literatürünün aksine, veri setinde sigara içmeyenlerin kalp hastası olma oranı (%34.21), düzenli sigara içenlerden (%27.66) daha yüksek çıkmıştır. Bu durum veri setinin küçük olmasına ve verilerin klinik ölçüm yerine "self-reported" (katılımcı öz-beyanı) yoluyla toplanmasına (anket hatası) bağlanmıştır.
- **Model Başarıları:** Kalp hastası olup olmamayı tahmin etmek üzere eğitilen modellerden **Logistic Regression** (%71.21 Doğruluk ve 0.790 ROC-AUC), Karar Ağacı modeline (%69.70 Doğruluk) kıyasla daha başarılı olmuştur.
- **Teşhis Yetersizliği (Düşük Recall):** Her iki model de sağlıklı bireyleri çok iyi ayırt edebilirken, gerçek kalp hastalarını yakalamakta başarısız olmuştur. En başarılı model olan Lojistik Regresyon bile gerçek hastaların sadece %32'sini (Recall) yakalayabilmiş, hastaların %68'ini gözden kaçırmıştır.
- **Klinik Karar Durumu:** Elde edilen bulgular ve %32'lik düşük hasta yakalama oranı (Recall) göz önüne alındığında, **bu veri seti ve modellerle gerçek hayatta klinik bir karar verilmesi kesinlikle imkansızdır.** Hayati risk taşıyan kardiyovasküler teşhis sistemlerinde bu denli yüksek hata payı tıbbi açıdan kabul edilemez.